Московский Государственный Технический Университет им. Н.Э. Баумана

Отчет по лабораторной работе №4 по курсу Технологии Машинного Обучения

Выполнил:
Муравьев О.М.
ИУ5-62
Прородин
Проверил:
Гапанюк Ю.Е.

Задание

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите модель ближайших соседей для произвольно заданного гиперпараметра К. Оцените качество модели с помощью трех подходящих для задачи метрик.
- 5. Постройте модель и оцените качество модели с использованием кросс-валидации. Проведите эксперименты с тремя различными стратегиями кросс-валидации.
- 6. Произведите подбор гиперпараметра К с использованием GridSearchCV и кросс-валидации.
- 7. Повторите пункт 4 для найденного оптимального значения гиперпараметра К. Сравните качество полученной модели с качеством модели, полученной в пункте 4.
- 8. Постройте кривые обучения и валидации.

Код и результаты выполнения

1. Подключим библиотеки:

Как мы видим пропущенных значений нет

```
import pandas as pd
from enum import Enum
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from operator import itemgetter
import matplotlib.pyplot as plt
import numpy as np
```

2. Подготовим набор данных к работе

Проверим наличие пропущенных значениений nd = data.columns[data.isnull().any()] print(len(nd)) 12 О Имеем 12 столбцов с категориальными признаками

Заменим категориальные признаки числовыми используя Label encoding

```
le = LabelEncoder()
for col in cats:
    data[col]=le.fit_transform(data[col])

newcats = [col for col in data.columns if data[col].dtype=="object"]
print(len(newcats))
```

3. Разделим выборку на обучающую и тестовую

```
X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42)

# Размер тренировочной выборки
print(X_train.shape, y_train.shape)
# Размер тестовой выборки
print(X_test.shape, y_test.shape)

(6980, 55) (6980,)
(1746, 55) (1746,)
```

4. Построение и оценка модели

Проверим модель при помощи метрик R2, MSE, MedAE

R2(y test, a)

```
Обучим модель используя метод к близжайших значений
                                                                                                                        0.35347216945585735
 KNN = KNeighborsRegressor()
KNN.fit(X_train,y_train)
                                                                                                                        MSE(y test, a)
 KNeighborsRegressor(algorithm='auto', leaf_size=30, metric='minkowski',
                                                                                                                        98227.06495687284
                metric_params=None, n_jobs=None, n_neighbors=5, p=2,
weights='uniform')
                                                                                                                        MedAE(y test, a)
 a= KNN.predict(X test)
                                                                                                                        87.82000000000001
                                                                                                                            random_search_kFold.fit(x,y)
                                                                                                                           Gridsearch(vvewKr01d(n.gplitm=5, random_state=None, shuffle=False),
error_score='raise-deprecating',
estimator='Reisphorsakgressor(algorithm='auto', leaf_size=30, metric='minkowski',
metric_parama=None, n_jobs=None, n_neisphors=5, p=2,
weights='uniform',
fit_parama=None, iid='warn', n_jobs=None,
param_grid=('n_neisphors': [i, 2, 3, 4, 5, 10, 25, 40, 50, 100, 250, 500, 1000]),
pre_dispatch='2'n_jobs', refit=True, returm_train_score='warn',
scoring='2'', verbose=0)
Обучим модель при помощи кросс валидации тремя стратегиями и подберем гиперпараметры
                                                                                                                            random search kFold.best para
11 = [1,2,3,4,5,10,25,40,50,100,250,500,1000]
                                                                                                                            {'n_neighbors': 1000}
                                                                                                                            random_search_kPold = GridSearchCV(estimator= KNeighborsRegressor(),
param_grid='('n_neighbors': 11),
scoring-'nea_mean_squared_error',
cv= KFold(n_splits=5))
scores = cross_val_score(KNeighborsRegressor(n_neighbors=5),x, y,cv=KFold(n_splits=5), scoring = 'r2')
print(np.mean(scores))
-0.5471605374343553
                                                                                                                            random_search_kFold.fit(x,y)
scores = -1°cross_val_score(RNeighborsRegressor(n_neighbors*5),x, y,cv=RFold(n_splits*5), scoring = 'neg_mean_squared_c
print(np.mean(scores))
                                                                                                                          GridSearch(V(cw-KFold(n_splits=5, random_state=None, shuffle=False),
error_score='raise-deprecating',
estimator='Risejsborgerssor(algorithm='auto', leaf_size=30, metric='minkowski',
metric_parame=None, n_olos=None, n_noispbors=5, p=2,
weights='uniform', n_jobs=None, n_noispbors=5, p=2,
weights='uniform', n_jobs=None,
param_grid='(n_sejsbors') (1, 2, 3, 4, 5, 10, 25, 40, 50, 100, 250, 500, 1000]),
parametric = n_jobs='deferted=kensutrain_score='warn',
scoring='neg_men_squard_error', verbose=0)
196526.4650782841
scores = -1*cross_val_score(KNeighborsRegressor(n_neighbors=5),x, y,cv=KFold(n_splits=5), scoring = 'neg_median_absolut
print(np.mean(scores))
163.50959999999998
random search kFold.best params
                                                                                                                            {'n_neighbors': 1000}
random search kFold.fit(x,y)
GridSearch(v(owKPold(n, splits=5, random_state=None, shuffle=False),
error_score='raise-deprecating',
estimator=KneighborsRegressor(algorithm='auto', leaf_size=30, metric='minkowski',
metric_params=None, n_jobs=None, n_meighbors=5, p=2,
weights='uniform'),
fit_params=None, iid='warn', n_jobs=None,
param_gride'('n_neighbors': [1, 2, 3, 4, 5, 10, 25, 40, 50, 100, 250, 500, 1000]),
pre_dispatch':27m_jobs', refit=True, return_train_score='warn',
scoring='neg_median_absolute_error', verbose=0)
                                                                                                                  print(np.mean(scores))
                                                                                                                  0.39628696314739453
                                                                                                                  random_search_kFold
                                                                                                                  print(np.mean(scores))
 {'n neighbors': 10}
                                                                                                                  82540.63936477728
 print(np.mean(scores))
-0.06260425742921458
                                                                                                                  print(np.mean(scores))
 print(np.mean(scores))
                                                                                                                  136522.2623284804
 random_search_Shuffled.fit(x,y)
 random_search_Shuffled.best_params_
 {'n_neighbors': 3}
                                                                                                                  random_search_Shuffled.best_params_
{'n_neighbors': 3}
                                                                                                                  random_search_Shuffled.fit(x,y)
GridSearchCV(cv=ShuffleSplit(n_splits=5, random_state=None, test_size=0.25, train_size=None),
    error_score='raise-deprecating',
    estimator=KNeighborsRegressor(algorithm='auto', leaf_size=30, metric='minkowski',
    metric_params=None, n_jobs=None, n_neighbors=5, p=2,
        weights='uniform'),
    fit_params=None, ide'warn', n_jobs=None,
    param_grid=('n_neighbors': [1, 2, 3, 4, 5, 10, 25, 40, 50, 100, 250, 500, 1000]),
    pre_dispatch='2'n_jobs', refit=True, return train_score='warn',
    scoring='neg_mean_squared_error', verbose=0)
                                                                                                                  print(np.mean(scores))
                                                                                                                  0.39840144338554095
                                                                                                                  print(np.mean(scores))
random_search_Shuffled.best_params_
                                                                                                                  76819.15214048987
 {'n neighbors': 3}
                                                                                                                  print(np.mean(scores))
random search Shuffled.fit(x,y)
                                                                                                                  81.009333333333333
```

3. RepeatedKFold

```
random_search_n_kFold.best_params_
: scores = cross_val_score(KNeighborsRegressor(n_neighbors=5),x, y, cv=RepeatedKFold(n_splits=5, n_repeats=5), scoring = 'r2')
                                                                                                                                          0.38647630284365564
: scores = -1 * cross_val_score(KNeighborsRegressor(n_neighbors=5),x, y, cv=RepeatedKFold(n_splits=5, n_repeats=5), scoring = 'neg_mean_squared_error')
                                                                                                                                          random_search_n_kFold.fit(x, y)
                                                                                                                                          GridSearchCV(cv=csklearn.model_selection.split.RepeatedKFold object at 0x1256aa908>,
    error_score='raise-deprecating',
    estimator=KNeighborsRegressor(algorithm='auto', leaf_size=30, metric='minkowski',
    metric_params=None, n_jobs=None, n_neighbors=5, p=2,
    weights='uniform'),
    fit_params=None, id='warn', n_jobs=None,
    param_grid=('n_neighbors': [1, 2, 3, 4, 5, 10, 25, 40, 50, 100, 250, 500, 1000]),
    pre_dispatch='2'n_jobs', refit=True, return_train_score='warn',
    scoring='neg_mean_squared_error', verbose=0)
   print(np.mean(scores))
   81875.4771649273
print(np.mean(scores))
                                                                                                                                          random_search_n_kFold.best_params_
random_search_n_kFold = GridSearchCV(estimator= KNeighborsRegressor(), param_grid= {'n_neighbors': 11}, scoring= 'neg_median_absolute_error', cv= RepeatedKFold(n_splits=5, n_repeats=5))
random_search_n_kFold.fit(x, y)
                                                                                                                                          random_search_n_kFold.fit(x, y)
```

5. Кривая обучения и валидации

